



**PROGRAMA DE PÓS-GRADUAÇÃO
ESPECIALIZAÇÃO EM ESTATÍSTICA APLICADA**

MODELOS LINEARES

Salvador

2019

ANA PAULA DE SOUZA VANDERLEY

MODELOS LINEARES

Trabalho apresentado ao Curso de
Especialização em Estatística Aplicada do
Centro Universitário Jorge Amado, como
requisito para a conclusão da disciplina
Modelos lineares, sob a orientação do
Profº Jackson Conceição..

Salvador

2019

SUMÁRIO

1 INTRODUÇÃO

2 ANÁLISE DESCRIPTIVA

3 AJUSTE DO MODELO

4 INFERÊNCIA DOS PARÂMETROS DO MODELO

5 DIAGNÓSTICO DO MODELO PROPOSTO

6 CONSIDERAÇÕES FINAIS

1- INTRODUÇÃO

Modelos Lineares Generalizados é uma extensão dos modelos de regressão simples e múltipla, pois possibilitam outras distribuições para os erros e uma função de ligação relacionada a média da variável resposta à combinação linear das variáveis explicativas.

O Objetivo portanto é analisar a influência que uma ou mais variáveis (explicativas), medidas em indivíduos ou objetos, tem sobre uma variável de interesse a que damos o nome de variável resposta. Através do estudo de um modelo de regressão que relate essa variável de interesse com as variáveis ditas explicativas.

Permitindo assim definir o comportamento (distribuição) da variável resposta, as variáveis explicativas, a função que irá ligar as variáveis explicativas a variável resposta. Com os modelos lineares generalizados é possível modelar variáveis de interesse que assumem a forma de contagem, contínuas simétricas e assimétricas, binárias e categóricas.

No caso desse Trabalho vamos estudar a relação da variável dependente GORDURA (Y) com as demais variáveis independentes (X). Afim de determinar quais variáveis tem mais correlação com a variável resposta e ajustar um modelo que explique melhor determinado comportamento

Analisaremos a associação do percentual de gordura corporal em uma amostra de 252 homens junto com diversas outras medidas corporais. O objetivo é fazer um modelo linear que permita obter o percentual de gordura (desfecho) usando medidas do corpo fáceis de serem obtidas. As variáveis do estudo serão ID , gordura, peso, abdomen ,idade, adiposidade, pescoço, quadril, braço.

TODOS OS COMANDOS DO R ESTÃO EM AZUL.

IMPORTANDO BANCO DE DADOS

```
rm(list = ls(all = TRUE))
setwd("~/R/tabela.xlsx")
tabela <- read_excel("tabela.xlsx")
```

CRIANDO VARIAVEIS

```
id<-c(1:252)
gordura<-c(0:45.1)
idade<-c(22:81)
peso<-c(118.5:363.15)
altura<-c(29.5:77.75)
adip<-c(18.1:48.9)
pesc<-c(31.1:51.2)
abdomem<-c(69.4:148.1)
quadril<-c(85:147.7)
braco<-c(24.8:45)
```

```
head(tabela)
```

ID	gordura	idade	peso	altura	adip	pesc	abdomem	quadril	braco
<db7>	<db7>	<db7>	<db7>	<db7>	<db7>	<db7>	<db7>	<db7>	<db7>
1	1	12.6	23	154.	67.8	23.7	36.2	85.2	94.5
2	2	6.9	22	173.	72.2	23.4	38.5	83	98.7
3	3	24.6	22	154	66.2	24.7	34	87.9	99.2
4	4	10.9	26	185.	72.2	24.9	37.4	86.4	101.
5	5	27.8	24	184.	71.2	25.6	34.4	100	102.
6	6	20.6	24	210.	74.8	26.5	39	94.4	108.

Acima temos uma breve leitura do conjunto de dados. O banco de dados possui 252 observações, 9 variáveis sendo uma variável resposta GORDURA e 8 variáveis explicativas.

CARREGANDO PACOTES

```
library(readxl)
library(ggplot2)
library(scales)
library(mtcars)
library(faraway)
```

2 - ANÁLISE DESCRIPTIVA DAS VARIÁVEIS

```
> summary(tabela)
      ID      gordura      idade      peso      altura      adip      pesc
Min. : 1.00  Min. : 0.00  Min. :22.00  Min. :118.5  Min. :29.50  Min. :18.10  Min. :31.10
1st Qu.: 63.75  1st Qu.:12.80  1st Qu.:35.75  1st Qu.:159.0  1st Qu.:68.25  1st Qu.:23.10  1st Qu.:36.40
Median :126.50  Median :19.00  Median :43.00  Median :176.5  Median :70.00  Median :25.05  Median :38.00
Mean   :126.50  Mean   :18.94  Mean   :44.88  Mean   :178.9  Mean   :70.15  Mean   :25.44  Mean   :37.99
3rd Qu.:189.25  3rd Qu.:24.60  3rd Qu.:54.00  3rd Qu.:197.0  3rd Qu.:72.25  3rd Qu.:27.32  3rd Qu.:39.42
Max.  :252.00  Max.  :45.10  Max.  :81.00  Max.  :363.1  Max.  :77.75  Max.  :48.90  Max.  :51.20
      abdomen     quadril     braço
Min. : 69.40  Min. : 85.0  Min. :24.80
1st Qu.: 84.58  1st Qu.: 95.5  1st Qu.:30.20
Median : 90.95  Median : 99.3  Median :32.05
Mean   : 92.56  Mean   : 99.9  Mean   :32.27
3rd Qu.: 99.33  3rd Qu.:103.5  3rd Qu.:34.33
Max.  :148.10  Max.  :147.7  Max.  :45.00
```

Algumas variáveis apresentaram dados de média e mediana muito próximos, o que indica uma baixa dispersão dos dados. Abaixo uma análise do desvio padrão e variância das variáveis.

Desvio Padrão:

```
> sd(gordura)
[1] 7.750856
> sd(idade)
[1] 12.60204
> sd(peso)
[1] 29.38916
> sd(altura)
[1] 3.662856
> sd(adip)
[1] 3.648111
> sd(pesc)
[1] 2.430913
> sd(abdomem)
[1] 10.78308
> sd(quadril)
[1] 7.164058
> sd(braço)
[1] 3.021274
```


o desvio padrão indica qual é o “erro” se quiséssemos substituir um dos valores coletados pelo valor da média.

```
> var(tabela)
      gordura     idade     peso    altura    adip    pesc  abdomem  quadril    braço
gordura 60.075763 28.245483 139.671527 -2.5297548 20.5847491 9.260466 68.007997 34.743601 11.545529
idade   28.245483 158.811405 -4.720686 -7.9230459 5.4640249 3.477171 31.310050 -4.544071 -1.567215
peso    139.671527 -4.720686 863.722719 33.1856467 95.1373826 59.348441 281.410541 198.099047 71.071090
altura  -2.529755 -7.923046 33.185647 13.4165125 -0.3326053 2.259054 3.468334 4.471301 2.299789
adip    20.584749 5.464025 95.137383 -0.3326053 13.3087123 6.8982223 36.343465 23.084485 8.226603
pesc    9.260466 3.477171 59.348441 2.2590543 6.8982223 5.909339 19.766422 12.799440 5.369868
abdomem 68.007997 31.310050 281.410541 3.4683338 36.3434647 19.766422 116.274745 67.522123 22.315796
quadril 34.743601 -4.544071 198.099047 4.4713005 23.0844849 12.799440 67.522123 51.323722 16.001243
braço   11.545529 -1.567215 71.071090 2.2997889 8.2266026 5.369868 22.315796 16.001243 9.128095
```

Quanto maior for a variância, mais distantes da média estarão os valores, e quanto menor for a variância, mais próximos os valores estarão da média.

A seguir temos os histogramas das variáveis.

```
hist(gordura)
hist(idade)
hist(peso)
hist(altura)
hist(adip)
hist(pesc)
hist(quadril)
hist(braço)
```



Podemos notar através dos histogramas acima a dispersão dos dados.

As variáveis apresentaram maior concentração de dados :

Gordura: entre 10% a 30%

Idade: entre 40 e 50 anos.

Peso: entre 150 e 200 libras.

Altura: 65 e 75 unidades ¹

Adiposidade: 20 a 30 unidades ²

Pescoço: 35 a 45 centímetros

Abdômen: 80 e 100 centímetros

Quadril: 95 e 105 centímetros

Braço: 30 a 35 centímetros


CORRELAÇÃO DAS VARIÁVEIS

```
> cor(tabela)
      ID     gordura      idade      peso     altura     adip      pesc     abdomem    quadril
ID  1.00000000  0.11095086  0.34125350  0.03372794  0.04094313  0.04771746  0.07111233  0.12171973 -0.02373697
gordura  0.11095086  1.00000000  0.28917352  0.61315611 -0.08910641  0.72799418  0.49148893  0.81370622  0.62569993
idade   0.34125350  0.28917352  1.00000000 -0.01274609 -0.17164514  0.11885126  0.11350519  0.23040942 -0.05033212
peso    0.03372794  0.61315611 -0.01274609  1.00000000  0.30827854  0.88735216  0.83071622  0.88799494  0.94088412
altura  0.04094313 -0.08910641 -0.17164514  0.30827854  1.00000000 -0.02489094  0.25370988  0.08781291  0.17039426
adip   0.04771746  0.72799418  0.11885126  0.88735216 -0.02489094  1.00000000  0.77785691  0.92388010  0.88326922
pesc   0.07111233  0.49148893  0.11350519  0.83071622  0.25370988  0.77785691  1.00000000  0.75407737  0.73495788
abdomem 0.12171973  0.81370622  0.23040942  0.88799494  0.08781291  0.92388010  0.75407737  1.00000000  0.87406618
quadril -0.02373697  0.62569993 -0.05033212  0.94088412  0.17039426  0.88326922  0.73495788  0.87406618  1.00000000
braço  -0.01567689  0.49303089 -0.04116212  0.80041593  0.20781557  0.74638418  0.73114592  0.68498272  0.73927252
           braço
ID  -0.01567689
gordura  0.49303089
idade   -0.04116212
peso    0.80041593
altura  0.20781557
adip   0.74638418
pesc   0.73114592
abdomem 0.68498272
quadril 0.73927252
braço  1.00000000
```


Depois de feita a correlação das variáveis podemos notar que a variável **gordura** tem uma forte correlação com as variáveis **peso**, **adip**, **pescoço**, **abdomem**, **quadril** e **braço**. Verificamos ocorrência de multicolinearidade, que pode influenciar o resultado do modelo. A Seguir os Gráficos de correlação das variáveis em estudo com a variável resposta GORDURA.

```
plot(idade, gordura)
plot(peso, gordura)
plot(altura, gordura)
plot(adip, gordura)
plot(pesc, gordura)
plot(abdomem, gordura)
plot(quadril, gordura)
plot(braço, gordura)
```


IDADE X GORDURA




PESO X GORDURA




ALTURA X GORDURA




ADIP X GORDURA




PESC X GORDURA




ABDOMEM X GORDURA



QUADRIL X GORDURA



BRAÇO X GORDURA



Através da análise dos gráficos podemos notar que existe uma significativa relação da **gordura** com as variáveis **Peso**, **Adiposidade e Abdômen**. As variáveis **Idade e Altura** não apresentaram nenhuma evidência de relação com a variável resposta **Gordura**

CRIANDO O DATA FRAME

```
tabela2 = data.frame(tabela ,produto)
attach(tabela2)
```

ESCALONAMENTO DAS VARIÁVEIS

```
tabela= scale(tabela)
tabela2 = scale(tabela2)
```

IDENTIFICANDO OCORRÊNCIA DE MULTICOLINEARIDADE

```
vif(tabela)
```

	Idade	Peso	Altura	Adip.	Circ. Pescoço	Circ. Abdômen	Circ. Quadril	Circ. Braço
VIF	1,57	24,36	2,21	13,43	4,02	17,12	11,94	3,15

Através da análise de **VIF (Variance Inflation Factors)** verificamos multicolinearidades em algumas variáveis apresentaram VIF maior que 10 o que pode causar problemas na estimação dos coeficientes. Vamos calcular novamente o VIF apenas com as variáveis que apresentaram maior correlação com a variável resposta gordura, que nesse caso foram peso, adip, abdomem e quadril. Criaremos um conjunto de valores apenas com essas variáveis e calcularemos novamente o VIF.

VARIÁVEL CRIADA PARA RESOLVER O PROBLEMA DE MULTICOLINEARIDADE

```
produto = (peso~adip~abdomem~quadril)
```

CALCULANDO O VIF NOVAMENTE:

	Idade	Altura	Circ. Pescoço	Circ. Braço	Produto
VIF	1,21	1,18	3,05	2,54	2,64

Verificamos que o problema de multicolinearidade foi solucionado, podemos agora ajustar o modelo para a solução do problema.

3 - AJUSTE DO MODELO

MEDINDO A SIGNIFICÂNCIA DAS VARIAVÉIS NO MODELO PROPOSTO.

```
summary(mod0 <- lm(gordura ~ ., data=tabela))

Call:
lm(formula = gordura ~ ., data = tabela)

Residuals:
    Min      1Q  Median      3Q     Max 
-10.0503 -3.0669  0.1313  2.9528 10.3543 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) -17.903673  13.184532 -1.358  0.17575  
ID          -0.002335  0.003831 -0.610  0.54274  
idade        0.004406  0.026339  0.167  0.86730  
peso         -0.091798  0.042969 -2.136  0.03365 *  
altura       -0.102157  0.104498 -0.978  0.32925  
adip          0.062689  0.259059  0.242  0.80899  
pesc          -0.548176  0.209627 -2.615  0.00948 ** 
abdomem       0.908096  0.080467 11.285 < 2e-16 *** 
quadril       -0.137004  0.125104 -1.095  0.27455  
braço          0.291270  0.150415  1.936  0.05398 .  
---

```

```
Signif. codes: 0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
Residual standard error: 4.085 on 242 degrees of freedom  
Multiple R-squared: 0.7322, Adjusted R-squared: 0.7223  
F-statistic: 73.53 on 9 and 242 DF, p-value: < 2.2e-16
```

MODELO 1

Para criarmos um modelo de regressão múltipla multiplicaríamos a variável resposta gordura mais todas as outras variáveis independentes como segue exemplo do modelo abaixo.

```
modgeral = lm(gordura ~ idade + peso + altura + adip + pesc + abdomen  
+ quadril + braço)
```

```
summary(modgeral)
```

```
step(modgeral)
```

```
GORDURA = -17.90 + 0.002335 ID - 0.004406 IDADE - 0.091798 PESO  
- 0.102157 ALTURA - 0.062689 ADIP - 0.548176 PESC - 0.908096 ABDOME  
M - 0.137004 QUADRIL - 0.291270 BRAÇO.
```

Porém esse primeiro modelo não é um modelo adequado para o estudo pois verificamos que algumas variáveis apresentaram pouca ou nenhuma significância para a explicação da variável dependente.

Algumas variáveis apresentaram valores muitos próximos de 0 ou seja variáveis com pouca significância para explicar a variável dependente. Não há porque colocar essas variáveis com valores muito perto de 0 no modelo. O Teste T nos mostra que devemos aceitar a hipótese H₀ pois os betas são muito próximos de 0. Após tirarmos as variáveis pouco significativas dos modelos vamos estimar novamente o modelo com as variáveis mais significativas .

MODELO 2

```
modproduto = lm(gordura ~ idade + altura + pesc + braço + produto)
summary(modproduto)
step(modproduto)
```

Usando o Stepwise para escolha das variáveis que devem compor o modelo final. O modelo final selecionado resultou na seguinte equação:

$$\text{Gordura} = 10,498 + \text{Idade} 0,156 - \text{Altura} 0,297 - \text{Braço} 0,689 - \text{Produto} 3,066$$

MODELO FINAL

```
modfinal = lm(gordura ~ idade + altura + braço + produto)
```

4– INFERÊNCIA DOS PARAMÉTROS DO MODELO

O método Stepwise para a seleção de variáveis é muito usado em regressão linear. Qualquer procedimento para seleção ou exclusão de variáveis de um modelo é baseado em um algoritmo que checa a importância das variáveis, incluindo ou excluindo-as do modelo se baseando em uma regra de decisão. A importância da variável é definida em termos de uma medida de significância estatística do coeficiente associado à variável para o modelo. Essa estatística depende das suposições do modelo.

Foi usado um intervalo de confiança de (95%) para testar as estimativas da regressão, o resultado nos mostra que o modelo sugerido pelo stepwise está certo pois ele eliminou a variável Pesc pois continha um intervalo de confiança iguais a 0 e não se pode considerar valores 0 por esse motivo não utilizaremos a variável Pesc No modelo final.



```
confint(modproduto)
confint(modfinal)
```

Variável	ID modelo 1		IC modelo final	
Intercepto	-11.617	27.775	-6.490	27.486
Idade	0.093	0.213	0.098	0.215
Altura	-0.521	-0.098	-0.502	-0.092
Pescoço	-0.393	0.647	---	
Braço	0.273	1.019	0.361	1.018
Produto	1.816	4.052	2.088	4.043

5 - DIAGNOSTICO DO MODELO

Usaremos os gráficos de resíduos para analisar a regressão.

```
qqnorm(rstudent(modfinal), ylab="Resíduos", main="")
qqline(rstudent(modfinal))
plot(gordura,rstudent(modfinal),ylab="Resíduos", main="",ylim=c(-3,3))
abline(h=0, lty=4)
abline(h=-2,lty=3)
abline(h=2,lty=3)
```



Através das análises dos resíduos podemos notar que os resíduos permanecem dentro do intervalo de confiança estimado de 95%. Logo o modelo é valido.

6 CONSIDERAÇÕES FINAIS

O banco de dados apresentou multicolinearidade entre as variáveis sendo necessária para a ajuste do modelo que se fizesse um conjunto de valores nele contendo as variáveis peso, adiposidade, abdômen e quadril. A variável criada produto junto com as outras variáveis explicou assim o modelo indicado.

Depois de feito o ajuste das variáveis o modelo indicado pelo *stepwise* o modelo ideal seria composto pelas variáveis Idade, Altura, Circunferência do Braço e Produto.

Foi possível avaliar a validade do modelo proposto pois os gráficos de resíduos usados para os testes mostraram que os dados se concentravam dentro do intervalo de confiança usado no trabalho que foi de 95%. Ou seja o modelo ajustado é sim capaz de explicar a variável resposta do estudo em questão.